

Wine Quality Prediction and Cluster Analysis: Using Data Mining Techniques to Group Wines by Similarity and Predict Quality

Κόνσουλας Κωνσταντίνος και Ευάγγελος Ζάμπρας

Εξόρυξη Δεδομένων 2022-23

Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών

Πανεπιστήμιο Θεσσαλίας, Βόλος

{kkonsoulas, ezampras}@uth.gr

1 Εισαγωγή

Το παρόν κείμενο αποτελεί μία σύντομη αναφορά σχετικά με την προγραμματιστική εργασία στα πλαίσια της εξόρυξης δεδομένων. Η συγκεκριμένη αναφορά περιέχει πληροφορίες σχετικά με την εφαρμογή που αναπτύξαμε, τα προβλήματα που καλείται να αντιμετωπίσει, την λειτουργικότητά της, τον τρόπο που γίνεται η εγκατάστασή της καθώς και οδηγίες σχετικά με την χρήση της.

1.1 Περιγραφή Εφαρμογής

Ας ξεκινήσουμε με την Περιγραφή της εφαρμογής μας και τα προβλήματα που τίθεται να επιλύσει. Ως γνωστόν υπάρχει μία ευρεία γκάμα από οίνους οι οποίοι έχουν ιδιαίτερα χαρακτηριστικά ως προς τους δείκτες οξύτητας, τον δείκτη pH, το χρώμα, την συγκέντρωση ζάχαρης, κιτρικού οξέως και άλλων χημικών χαρακτηριστικών. Για κάθε οίνο υπάρχει η μετρική της ποιότητας που εκφράζεται από μια boolean τιμή (καλής ή κακής ποιότητας κρασί) και όλα τα παραπάνω χαρακτηριστικά επηρεάζουν την τιμή αυτή. Ο στόχος της εφαρμογής μας, όπως αναφέραμε συνοπτικά και στην πρόταση εκπόνησης, είναι τρίπτυχος:

Classification Πρώτον, με βάση ένα δεδομένο dataset και με τη μέθοδο classification να μπορεί να αξιολογεί οίνους για την ποιότητά τους, μια διαδικασία που μας επιτρέπει έτσι να δημιουργήσουμε ένα σύστημα ώστε να αξιολογούμε οίνους ως προς την ποιότητά τους με ταχύτητα, ευκολία και αντικειμενικότητα.

Clustering Επιπλέον, να συσταδοποιεί (clustering) τους οίνους ώστε να παράγει ομάδες οίνων με παρόμοια χαρακτηριστικά και να εμφανίζει γραφικά αποτελέσματα ώστε να οπτικοποιεί τα χρήσιμα δεδομένα που εξαγάγαμε από την ανάλυση με τεχνικές data mining

Association Rule learning Τέλος, μέσω της τεχνικής του association rule mining να παράγει χρήσιμα συμπεράσματα για συσχετισμούς χαρακτηριστικών μεταξύ οίνων ώστε να μπορούμε να εντοπίσουμε τα μοτίβα που παρατηρούνται στο raw dataset και στη συνέχεια να τα εξηγήσουμε.

1.2 Μορφή Δεδομένων

Για την υλοποίηση της εφαρμογής πέρα από την γλώσσα python και τις σχετικές βιβλιοθήκες της που μας προσφέρουν εξαιρετικές δυνατότητες χρησιμοποιήσαμε και 2 datasets από το UC Irvine Machine Learning Repository τα οποία περιέχουν πέρα από τα χημικά χαρακτηριστικά των οίνων και την ποιότητάς τους με την μορφή ενός αριθμού από το 1 μέχρι 10.

Για τους σκοπούς της εφαρμογής μας ορίσαμε τους οίνους ως μη ποιοτικούς (0) και ποιοτικούς (1) στο πεδίο του quality θέτοντας την τιμή 1 εάν το πεδίο είχε τιμή μεγαλύτερη ή ίση με το 7, σε αντίθετη περίπτωση το πεδίο έπαιρνε την τιμή 0. Το πρώτο dataset περιέχει όλους τους κόκκινους οίνους ενώ το δεύτερο dataset περιέχει όλους τους λευκούς οίνους. Για την εφαρμογή μας συνενώσαμε αυτά τα δύο dataset προσθέτοντας και την πληροφορία του χρώματος ως μία boolean τιμή (0 ή 1) για περισσότερη πληροφορία. Αυτό πραγματοποιήθηκε με την βοήθεια του ακόλουθου κώδικα python.

```
#load white wines and mark them
df1 = pd.read_csv("winequality-white.csv", sep=';')
zeros = [0] * len(df1)
white_label = pd.DataFrame({'color':zeros}, dtype=int)
df1 = pd.concat([white_label, df1], axis=1)

#load red wines and mark them
df2 = pd.read_csv("winequality-red.csv", sep=';')
ones = [1] * len(df2)
red_label = pd.DataFrame({'color':ones}, dtype=int)
df2 = pd.concat([red_label, df2], axis=1)

#unite red and white wines and mix the dataset
df = pd.concat([df1, df2])
df = df.sort_index()
df = df.reset_index()
df = df.drop(['index'], axis=1)
df['quality'] = [1 if x>=7 else 0 for x in df.quality]
```

1.3 Οδηγίες Εγκατάστασης

Η εφαρμογή για την λειτουργία της προϋποθέτει την εγκατάσταση της python καθώς και ορισμένων βιβλιοθηκών τη, συγκεκριμένα την scikit-learn, την pandas, την matplotlib αλλά και την mlxtend. Για την εγκατάσταση της python μπορεί να συμβουλευτείτε το official documentation ενώ η εγκατάσταση των προαναφερθέντων βιβλιοθηκών μπορεί να επιτευχθεί με κάποιο package manager όπως το conda ή το pip.

2 Explanatory Data Analysis

Ας δούμε λίγο καλύτερα το νέο ενιαίο dataset οπτικοποιώντας τα διάφορα χαρακτηριστικά του κάνοντας ένα απλό Explanatory Data Analysis (EDA). Αρχικά με την μέθοδο `.describe()` που μας δίνει η βιβλιοθήκη pandas μπορούμε να δούμε στατιστικές πληροφορίες για τα διάφορα attributes του dataset όπως τον μέσο όρο, την τυπική απόκλιση, το ελάχιστο το μέγιστο καθώς και τιμές που βρίσκονται στο 25%, 50% και 75%. Μία αντίστοιχη μέθοδος η `.info()` μας προσφέρει χρήσιμη πληροφορία σχετικά με την ονομασία των χαρακτηριστικών, τον τύπο δεδομένων που έχουν καθώς και το πλήθος των τιμών οι οποίες όντως υπάρχουν και δεν είναι null. Τα output των εντολών φαίνονται παρακάτω:


	color	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides
count	6497.000	6497.000	6497.000	6497.000	6497.000	6497.000
mean	0.246114	7.215307	0.339666	0.318633	5.443235	0.056034
std	0.430779	1.296434	0.164636	0.145318	4.757804	0.035034
min	0.000000	3.800000	0.080000	0.000000	0.600000	0.009000
25%	0.000000	6.400000	0.230000	0.250000	1.800000	0.038000
50%	0.000000	7.000000	0.290000	0.310000	3.000000	0.047000
75%	0.000000	7.700000	0.400000	0.390000	8.100000	0.065000
max	1.000000	15.90000	1.580000	1.660000	65.80000	0.611000

	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
count	6497.000	6497.000	6497.000	6497.000	6497.000	6497.000	6497.000
mean	30.52531	115.7445	0.994697	3.218501	0.531268	10.49180	0.196552
std	17.74940	56.52185	0.002999	0.160787	0.148806	1.192712	0.397421
min	1.000000	6.000000	0.987110	2.720000	0.220000	8.000000	0.000000
25%	17.00000	77.00000	0.992340	3.110000	0.430000	9.500000	0.000000
50%	29.00000	118.0000	0.994890	3.210000	0.510000	10.30000	0.000000
75%	41.00000	156.0000	0.996990	3.320000	0.600000	11.30000	0.000000
max	289.0000	440.0000	1.038980	4.010000	2.000000	14.90000	1.000000


```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6497 entries, 0 to 6496
Data columns (total 13 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   color                                6497 non-null   int64
1   fixed acidity                        6497 non-null   float64
2   volatile acidity                    6497 non-null   float64
3   citric acid                         6497 non-null   float64
4   residual sugar                      6497 non-null   float64
5   chlorides                          6497 non-null   float64
6   free sulfur dioxide                6497 non-null   float64
7   total sulfur dioxide               6497 non-null   float64
8   density                           6497 non-null   float64
9   pH                                 6497 non-null   float64
10  sulphates                         6497 non-null   float64
11  alcohol                           6497 non-null   float64
12  quality                           6497 non-null   int64
dtypes: float64(11), int64(2)
memory usage: 660.0 KB
```

2.1 Οπτικοποίηση Χαρακτηριστικών

Με την βοήθεια της βιβλιοθήκης seaborn η οποία μας επιτρέπει να πραγματοποιήσουμε οπτικοποίηση των δεδομένων μας μπορέσαμε να δημιουργήσαμε κάποια διαγράμματα που δείχνουν την ποσοστιαία κατανομή των οίνων με βάση το χαρακτηριστικό της ποιότητας και με βάση το χαρακτηριστικό του χρώματος. Έτσι μπορούμε να διακρίνουμε εύκολα το πλήθος των ποιοτικών αλλά και των κόκκινων/λευκών οίνων στο dataset. Με την βοήθεια της βιβλιοθήκης seaborn η οποία μας επιτρέπει να πραγματοποιήσουμε οπτικοποίηση των δεδομένων μας μπορέσαμε να δημιουργήσουμε κάποια διαγράμματα που δείχνουν την ποσοστιαία κατανομή των οίνων με βάση το χαρακτηριστικό της ποιότητας και με βάση το χαρακτηριστικό του χρώματος. Έτσι μπορούμε να διακρίνουμε εύκολα το πλήθος των ποιοτικών αλλά και των κόκκινων/λευκών οίνων στο dataset. Τα γραφήματα φαίνονται παρακάτω:



Ενδεικτικά παραθέτουμε και μερικά ακόμα διαγράμματα τα οποία δείχνουν το πλήθος των οίνων για τις διάφορες τιμές pH, της υπολειπόμενης ζάχαρης, της οξύτητας και των θεικών αλάτων. Οι τιμές στον άξονα X δεν είναι ορατές λόγω του πλήθους τους αλλά μπορούμε να καταλάβουμε σε γενικές γραμμές την κατανομή των τιμών.



2.2 Οπτικοποίηση Συσχέτισης Χαρακτηριστικών

Ακόμα μπορούμε να παράξουμε και όλα τα διαγράμματα τα οποία δείχνουν την διασπορά των οίνων για κάθε πιθανό ζεύγος χαρακτηριστικών. Η βιβλιοθήκη μας παρέχει επιπροσθέτως και την συνάρτηση `heatmap` η οποία μας επιτρέπει να οπτικοποιήσουμε την συσχέτιση των χαρακτηριστικών με βάση μία χρωματική παλέτα.

3 Λειτουργικότητα Εφαρμογής

Αφού είδαμε τις βιβλιοθήκες που χρησιμοποιούμε και πώς μας βοηθούν να κατανοήσουμε καλύτερα τα δεδομένα του dataset, ας προχωρήσουμε στη λειτουργία της εφαρμογής και τις δυνατότητες που παρέχει στον χρήστη. Όπως αναφέραμε, η εφαρμογή μας αποτελείται από 3 σκέλη και δίνει στον χρήστη τη δυνατότητα να πραγματοποιήσει 3 διαφορετικές λειτουργίες:

- **classification** για την πρόβλεψη της ποιότητας ενός οίνου με βάση τα δεδομένα του dataset, δηλαδή των χημικών χαρακτηριστικών που συμβάλλουν στην ποιότητα.
- **clustering** για την ομαδοποίηση των οίνων με βάση 2 επιλεγμένα από το χρήστη χαρακτηριστικά

- **association rule learning** το οποίο παράγει κανόνες που μας επιτρέπουν να συσχετίσουμε χαρακτηριστικά μεταξύ τους με βάση τα μοτίβα που αντλούνται από τα δεδομένα του dataset

Ο χρήστης μπορεί να χρησιμοποιήσει οποιοδήποτε dataset επιθυμεί και να πραγματοποιήσει τις λειτουργίες της εφαρμογής για όποια από τα χαρακτηριστικά θέλει. Στη συνέχεια θα εξηγήσουμε αναλυτικά πως σχεδιάσαμε και κατασκευάσαμε τα μέρη της εφαρμογής και ποια εργαλεία/αλγόριθμους επιλέξαμε για τις λειτουργίες της.

3.1 Classification

Στο πλαίσιο του classification είχαμε αρκετές επιλογές όσον αφορά το μοντέλο που θα χρησιμοποιήσουμε για τον χειρισμό των δεδομένων. Οι τρεις επικρατέστερες ήταν η μέθοδος του **Logistic Regression**, το **Random Forest Classification** και η μέθοδος **Gaussian Naive Bayes**. Για την επιλογή του κατάλληλου αλγορίθμου εκτελέσαμε training και testing σε ένα 80/20 split του dataset και μετρήσαμε τα evaluation metrics (accuracy, precision, recall, f1 και auc score).

Με βάση τις μετρικές αυτές και τα αποτελέσματα των πειραμάτων μας καταλήξαμε στο ότι το **Random Forest Classification** είναι η βέλτιστη μέθοδος classification των δεδομένων μας. Στην εφαρμογή μας, η εντολή που πρέπει να εισάγει ο χρήστης για το classification είναι η εξής:

```
$python dataMining.py -T train_data_file.csv input_data_file.csv output_file
```

Η εντολή αυτή παράγει ένα αρχείο εξόδου το οποίο κατηγοριοποιεί τους οίνους σε ποιοτικούς και μη ποιοτικούς.

3.2 Clustering

Στη συνέχεια θα παρουσιάσουμε τις δυνατότητες clustering που παρέχει η εφαρμογή. Αρχικά, έπρεπε να καθορίσουμε τον αριθμό clusters στα οποία θα χωριστούν τα αντικείμενα του dataset που αναλύουμε. Ως γνωστόν, η τιμή αυτή είναι δυνατόν να καθοριστεί από τον χρήστη χρησιμοποιώντας οπτικές μεθόδους όπως το elbow method, ή να υπολογιστεί αυτόματα τρέχοντας κάποιον αλγόριθμο πάνω στα πηγαία δεδομένα. Εμείς επιλέξαμε το δεύτερο τρόπο ώστε η εφαρμογή μας να είναι πιο λειτουργική και ευέλικτη για κάθε dataset που μπορεί να επιλεγεί από τον χρήστη.

Συγκεκριμένα, χρησιμοποιήσαμε το silhouette method για να υπολογίσουμε τον αριθμό των clusters, μια μέθοδος η οποία υπολογίζει μια μετρική που ονομάζεται silhouette coefficient για διαφορετικές τιμές $n_clusters$, και μας δείχνει την ιδανική τιμή clusters με βάση πότε η μετρική αυτή μεγιστοποιείται. Επομένως τρέξαμε τον ακόλουθο κώδικα python για να υπολογίσουμε την ιδανική τιμή του $n_clusters$.

```

#create dataframe with attributes to be clustered
user_select_attr1 = df[attr1]
user_select_attr2 = df[attr2]
clusterData1 = pd.concat([user_select_attr1,user_select_attr2],axis=1)

#find optimal number of clusters using silhouette method
range_n_clusters = [2, 3, 4, 5, 6, 7, 8, 9, 10]
silhouette_scores_array = []
for n_clusters in range_n_clusters:
    clusterer = KMeans(n_clusters=n_clusters, n_init="auto", random_state=42)
    cluster_labels = clusterer.fit_predict(clusterData1)
    silhouette_avg = silhouette_score(clusterData1, cluster_labels)
    silhouette_scores_array.append((n_clusters,silhouette_avg))
n_clusters = max(silhouette_scores_array,key=itemgetter(1))[0]

```

Έτσι έχουμε έναν αυτοματοποιημένο τρόπο να υπολογίζουμε δυναμικά τον αριθμό των clusters για την συσταδοποίηση των δεδομένων, κάτι το οποίο είναι ένα από τα πιο σημαντικά ζητήματα όσον αφορά τη διαδικασία αυτή.

Για το ίδιο το clustering χρησιμοποιήσαμε τον αλγόριθμο K-means, αποτελεί έναν πολύ καλό αλγόριθμο για την μείωση του variance μεταξύ των δεδομένων τα οποία ανήκουν σε ένα cluster αλλά δεν είναι ιδανικός για μεγάλα dataset. Στην περίπτωση μας το clustering γίνεται στιγμιαία για ολόκληρο το dataset επομένως δεν τίθεται θέμα ταχύτητας.

Εφόσον το dataset μας περιλαμβάνει 11 χαρακτηριστικά, για να χωρίσουμε τους οίκους σε clusters διδιάστατου χώρου πρέπει να επιλεγούν 2 από αυτά. Μέσω της εφαρμογής δίνουμε τη δυνατότητα στον χρήστη να επιλέξει με βάση ποια χαρακτηριστικά θέλει να κάνει το clustering.

Χρησιμοποιώντας τη βιβλιοθήκη matplotlib εξάγουμε τα clusters σε γραφική μορφή και παρουσιάζουμε ένα plot στον χρήστη. Επιπλέον παράγεται και ένα αρχείο εξόδου το οποίο μας δείχνει σε ποιο cluster ανήκει ο κάθε οίκος. Για να τρέξουμε τη λειτουργία του clustering εκτελούμε την εντολή:

```
$python dataMining.py -C data.csv attribute1 attribute2 outputFile
```

3.3 Association Rule Learning

Στη συνέχεια θα εξηγήσουμε πως λειτουργεί το association rule learning που εκτελεί η εφαρμογή μας, που είναι και το τρίτο και τελευταίο τμήμα της. Χρησιμοποιήσαμε τον αλγόριθμο apriori ο οποίος παράγει frequent item sets με βάση κάποιες συνθήκες που ελέγχει επί των δεδομένων. Στη συνέχεια τα sets αυτά μπορούν να χρησιμοποιηθούν για την παραγωγή association rules.

Αρχικά χωρίζουμε τα δεδομένα κάθε στήλης σε 5 στήλες ή αλλιώς 5 διακριτά bins τα οποία διαιρούν ισόποσα το εύρος τιμών κάθε στήλης. Το χαρακτηριστικό ανάλογα με την τιμή που έχει θέτει την τιμή 1 στην κατάλληλη στήλη και στις υπόλοιπες θέτει 0. Στη συνέχεια ο αλγόριθμος ανακαλύπτει τις σχέσεις μεταξύ των χαρακτηριστικών και εξάγει τους κανόνες σε ένα αρχείο εξόδου. Η εντολή που εκτελούμε για αυτό το τμήμα της εφαρμογής είναι η εξής:

```
$python dataMining.py -A data_for_assoc_rule.csv outputFile
```